

Τεχνητή Νοημοσύνη II

ECE_AK813

Εργασία εξαμήνου

Face Detection and Emotion Recognition

Κωτσάκης Γρηγόρης, AM: 1066610, ΣΜΗΝ

Παυλοπούλου Ανδρονίκη, AM: 1020236, ΣΜΗΝ

Πολίτης Βασίλης, AM: 1126191, ΣΜΗΝ

Τσάμπρας Κωνσταντίνος, AM: 1083865, ΣΜΗΝ

Περιεχόμενα

Εισαγωγή	5
Μέρος Α	5
Ερώτημα 2 - Εντοπισμός Προσώπων με ResNet	5
1. Εισαγωγή	5
2. Θεωρητικό Υπόβαθρο	5
3. Περιγραφή Dataset	6
4. Ανάλυση Κώδικα	6
5. Υπερπαράμετροι και Επιλογές	11
6. Εκπαίδευση και Αποτελέσματα	11
7. Συμπεράσματα	13
Ερώτημα 3 - Εντοπισμός Προσώπων με Vision Transformer	13
1. Εισαγωγή & Στόχος	13
2. Αρχιτεκτονική του Νευρωνικού Δικτύου	14
3. Διαδικασία Εκπαίδευσης & Σύνολο Δεδομένων (WIDER FACE)	15
4. Hyperparameter Search (Επιλογή Υπερπαραμέτρων)	15
5. Πλήρης Εκπαίδευση	16
6. Αποτελέσματα	17
Μέρος Β	20
Ερώτημα 6 - Αναγνώριση Συναισθημάτων με Συνελκτικό Νευρωνικό Δίκτυο (CNN)	20
1. Dataset	20
2. Split	21
3. Architecture	22
4. Training	22
5. Results	22
Ερώτημα 7 - Αναγνώριση Συναισθημάτων με Vision Transformer	27
1. Data Handling, Regularization και Stratified Split	27
2. Αρχιτεκτονική Μοντέλου και Βελτιστοποίηση	28
3. Αξιολόγηση Αποτελεσμάτων	29

4. Explainability και Attention Maps	31
5. Σύγκριση Μεθόδων ViT και CNN	32
Bonus	33

Κατάλογος Εικόνων & Πινάκων

Εικόνα 1. Επιλογή συσκευής εκτέλεσης (GPU/CPU).....	6
Εικόνα 2. Ορισμός υπερπαραμέτρων του μοντέλου	7
Εικόνα 3. Η κλάση WiderFaceDataset	8
Εικόνα 4. Αρχιτεκτονική μοντέλου: ResNet18 backbone και YOLO-style κεφαλή	9
Εικόνα 5. Συνάρτηση κόστους (YOLO Loss).....	9
Εικόνα 6. Συνάρτηση εκπαίδευσης μίας εποχής (train_one_epoch)	10
Εικόνα 7. Συνάρτηση επαλήθευσης (validate)	11
Εικόνα 8. Καμπύλες Training και Validation Loss (ResNet)	12
Εικόνα 9. Παράδειγμα ανίχνευσης προσώπων με τιμές confidence.....	12
Πίνακας 1. Επίπεδα Κεφαλής YOLO.....	14
Εικόνα 10. Hyperparameter Search	16
Εικόνα 11. Learning Curves	17
Εικόνα 12. Confidence Threshold	17
Εικόνα 13. ViT πρόβλεψη σε σχέση με την πραγματικότητα.....	18
Εικόνα 14. ViT Attention Map	19
Εικόνα 15. Εξέλιξη Self-Attention	20
Πίνακας 2. Κατανομή εικόνων ανά συναίσθημα (FER-2013)	21
Πίνακας 3. Αναφορά ταξινόμησης CNN (ανά συναίσθημα).....	23
Εικόνα 16. Confusion Matrix (CNN, κανονικοποιημένο)	24
Εικόνα 17. Παραδείγματα λανθασμένης ταξινόμησης (πρόβλεψη / πραγματική κλάση)	25
Εικόνα 18. Καμπύλες Loss (Training & Validation) — CNN	26
Εικόνα 19. Καμπύλες Accuracy (Training & Validation) — CNN	26
Πίνακας 4. Αξιολόγηση στο Test Set (ViT)	29

Εικόνα 20. Loss Curve & Validation Accuracy (ViT)	30
Εικόνα 21. Confusion Matrix (ViT)	31
Εικόνα 22. Attention Maps (ViT)	32
Εικόνα 23. Bonus — Ζωντανή ανίχνευση και αναγνώριση συναισθήματος (Angry)	34
Εικόνα 24. Bonus — Ζωντανή ανίχνευση και αναγνώριση συναισθήματος (Happy)	35

Εισαγωγή

Η παρούσα εργασία πραγματεύεται τον εντοπισμό προσώπων (Face Detection) και την αναγνώριση συναισθημάτων (Emotion Recognition) με χρήση τεχνικών βαθιάς μάθησης. Στο Μέρος Α υλοποιούνται και συγκρίνονται μοντέλα εντοπισμού προσώπων βασισμένα σε ResNet και σε Vision Transformer, ενώ στο Μέρος Β μελετάται η αναγνώριση συναισθημάτων με Συνελικτικά Νευρωνικά Δίκτυα (CNN) και Vision Transformers. Ο πλήρης κώδικας της υλοποίησης είναι διαθέσιμος στο αποθετήριο: <https://github.com/ultrongr/FaceDetection-EmotionRecognition>.

Μέρος Α

Το πρώτο μέρος της εργασίας αφορά τη δημιουργία μοντέλων εντοπισμού προσώπων μέσα σε εικόνες. Η πρώτη υλοποίηση γίνεται με χρήση του CNN ResNet, και η δεύτερη με χρήση ViT.

Το WIDER FACE dataset αποτελείται από 32.203 εικόνες και έχει καταγεγραμμένα 393.703 πρόσωπα. Τα πρόσωπα είναι κατανεμημένα σε 61 κλάσεις και αποτελούνται από διαφορετικά μεγέθη, πόζες και αναλύσεις, ενώ κάθε εικόνα περιέχει και τυχαίο αριθμό προσώπων. Οι εικόνες είναι χωρισμένες σε train, validation και test σε αναλογία 40%/10%/50%.

Ερώτημα 2 - Εντοπισμός Προσώπων με ResNet

1. Εισαγωγή

Σκοπός της παρούσας εργασίας είναι η ανάπτυξη ενός νευρωνικού δικτύου για τον εντοπισμό προσώπων σε εικόνες. Η προσέγγιση βασίζεται στον συνδυασμό ενός προεκπαιδευμένου νευρωνικού δικτύου τύπου ResNet για την εξαγωγή χαρακτηριστικών από τις εικόνες και μιας YOLO-style κεφαλής για την πρόβλεψη των κατάλληλων περιοχών ενδιαφέροντος. Το μοντέλο εκπαιδεύεται χρησιμοποιώντας το σύνολο δεδομένων WIDER FACE, ενώ η αξιολόγηση και η επιλογή υπερπαραμέτρων πραγματοποιείται με βάση το validation set.

2. Θεωρητικό Υπόβαθρο

Η ανίχνευση αντικειμένων αποτελεί βασικό πρόβλημα της υπολογιστικής όρασης και αφορά την ταυτόχρονη αναγνώριση και εντοπισμό αντικειμένων μέσα σε μια εικόνα. Στην παρούσα εργασία το ζητούμενο αντικείμενο είναι το ανθρώπινο πρόσωπο, και το σύστημα καλείται να εντοπίσει την ύπαρξή του και να προσδιορίσει τη θέση του μέσω ορθογώνιων περιοχών.

Τα συνελικτικά νευρωνικά δίκτυα είναι ιδιαίτερα κατάλληλα για την επεξεργασία εικόνων, καθώς επιτρέπουν την ανίχνευση χαρακτηριστικών όπως άκρα, υφές και σχήματα,

δημιουργώντας ιεραρχικές αναπαραστάσεις της πληροφορίας. Σε αυτή την εργασία χρησιμοποιείται το ResNet, ένα βαθύ νευρωνικό δίκτυο που κάνει χρήση residual συνδέσεων, οι οποίες επιτρέπουν την εκπαίδευση βαθύτερων αρχιτεκτονικών χωρίς την εμφάνιση φαινομένων όπως η εξαφάνιση του gradient. Το μοντέλο ResNet18 χρησιμοποιείται σε προεκπαιδευμένη μορφή, έχοντας ήδη μάθει σημαντικά χαρακτηριστικά από το dataset ImageNet. Στο αρχικό στάδιο εκπαίδευσης, τα βάρη του ResNet παραμένουν παγωμένα, έτσι ώστε να λειτουργεί αποκλειστικά ως extractor χαρακτηριστικών.

Η μέθοδος YOLO αποτελεί μια σύγχρονη προσέγγιση για ανίχνευση αντικειμένων, στην οποία η εικόνα χωρίζεται σε ένα πλέγμα και κάθε κελί προβλέπει την ύπαρξη αντικειμένων καθώς και τα αντίστοιχα bounding boxes. Με αυτόν τον τρόπο, η ανίχνευση επιτυγχάνεται σε ένα μόνο forward pass, γεγονός που καθιστά τη μέθοδο ιδιαίτερα αποδοτική. Στην παρούσα υλοποίηση, τα χαρακτηριστικά που εξάγονται από το ResNet χρησιμοποιούνται ως είσοδος σε μια YOLO-style κεφαλή, η οποία αναλαμβάνει την πρόβλεψη των bounding boxes.

3. Περιγραφή Dataset

Για την εκπαίδευση χρησιμοποιείται το WIDER FACE dataset, το οποίο περιλαμβάνει μεγάλο αριθμό εικόνων με πρόσωπα σε ποικίλες συνθήκες. Κάθε εικόνα συνοδεύεται από annotations που περιγράφουν τις θέσεις των προσώπων μέσω bounding boxes. Στον κώδικα πραγματοποιείται επεξεργασία του αρχείου annotations ώστε να εξαχθούν οι απαραίτητες πληροφορίες, ενώ διατηρούνται μόνο οι εικόνες που περιέχουν τουλάχιστον ένα πρόσωπο.

4. Ανάλυση Κώδικα

Η υλοποίηση ξεκινά με την εισαγωγή των απαραίτητων βιβλιοθηκών, όπως το PyTorch για την εκπαίδευση του μοντέλου και το torchvision για τη φόρτωση του προεκπαιδευμένου ResNet. Επιπλέον, γίνεται αυτόματη επιλογή της συσκευής εκτέλεσης, επιλέγοντας GPU εφόσον είναι διαθέσιμη.

```
# if exists: Gpu
DEVICE = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(f"used: {DEVICE}")
```

✓ 6.5s

used: cpu

Εικόνα 1. Επιλογή συσκευής εκτέλεσης (GPU/CPU)

Στη συνέχεια ορίζονται οι βασικές υπερπαράμετροι του μοντέλου: το μέγεθος της εικόνας εισόδου, το μέγεθος του grid για τη YOLO-style ανίχνευση, ο αριθμός των bounding boxes ανά κελί, το μέγεθος batch, ο ρυθμός μάθησης και ο αριθμός εποχών εκπαίδευσης. Επιπλέον,

ορίζονται παράμετροι που σχετίζονται με τη συνάρτηση κόστους, όπως τα βάρη σχετικά με τη σωστή τοποθέτηση των bounding boxes και τη σωστή εκτίμηση της ύπαρξης αντικειμένων.

```
2. Hyperparameters

# input image size
IMAGE_SIZE = 224

# grid size για YOLO-style detection
# ResNet, stride 32, 224/32 = 7
GRID_SIZE = 7

# bounding boxes per cell
NUM_BOXES_PER_CELL = 2

# Batch size για training
BATCH_SIZE = 16

# Learning rate
LEARNING_RATE = 1e-4

# epochs
NUM_EPOCHS = 10

# weights - loss function
LAMBDA_COORD = 5.0      # localization loss
LAMBDA_NOOBJ = 0.5      # confidence loss - no object

# Paths - WIDER FACE dataset
TRAIN_IMAGES_DIR = "data/WIDER_train/WIDER_train/images"
TRAIN_ANNOTATIONS_FILE = "data/wider_face_split/wider_face_split/wider_face_train_bbx_gt.txt"
VAL_IMAGES_DIR = "data/WIDER_val/WIDER_val/images"
VAL_ANNOTATIONS_FILE = "data/wider_face_split/wider_face_split/wider_face_val_bbx_gt.txt"

[2] ✓ 0.0s
```

Εικόνα 2. Ορισμός υπερπαραμέτρων του μοντέλου

Η Dataset class αναλαμβάνει τη φόρτωση των εικόνων και τη μετατροπή τους σε tensors, ενώ παράλληλα εφαρμόζει κανονικοποίηση σύμφωνα με στατιστικά του ImageNet. Επιπλέον, μετατρέπει τα bounding boxes σε μορφή συμβατή με τη λογική του YOLO, δηλαδή σε μορφή που αντιστοιχεί σε grid cells και περιλαμβάνει πληροφορία για τη θέση, το μέγεθος και την πιθανότητα ύπαρξης αντικειμένου.

```

class WiderFaceDataset(Dataset):
    """
    PyTorch Dataset for WIDER FACE dataset.

    every image -> tensor, bounding boxes -> YOLO-style target tensor
    """

    def __init__(self, annotations, image_size=224, grid_size=7, num_boxes=2):
        """
        Args:
            annotations: dicts list of 'image_path', 'boxes'
            image_size: resizing images
            grid_size: YOLO grid size (7x7)
            num_boxes: bounding boxes per cell
        """
        self.annotations = annotations
        self.image_size = image_size
        self.grid_size = grid_size
        self.num_boxes = num_boxes

        # Images Transformation
        self.transform = transforms.Compose([
            transforms.Resize(image_size, image_size),
            transforms.ToTensor(),
            # Normalization - ImageNet stats
            transforms.Normalize(
                mean=[0.485, 0.456, 0.406],
                std=[0.229, 0.224, 0.225]
            )
        ])

```

✓ 0.0s

Εικόνα 3. Η κλάση WiderFaceDataset

Η αρχιτεκτονική του μοντέλου αποτελείται από δύο βασικά μέρη:

- Το πρώτο μέρος είναι το ResNet18, από το οποίο διατηρούνται μόνο τα συνελκτικά επίπεδα, ενώ αφαιρούνται τα πλήρως συνδεδεμένα επίπεδα.
- Το δεύτερο μέρος είναι η κεφαλή ανίχνευσης YOLO, η οποία αποτελείται από διαδοχικά συνελκτικά επίπεδα και έχει ως σκοπό τη μετατροπή των extracted features από το backbone σε προβλέψεις bounding boxes.

Στο τελικό στάδιο εφαρμόζεται συνάρτηση sigmoid ώστε οι προβλέψεις να βρίσκονται σε κανονικοποιημένο εύρος.


```

# -----
# 1. ResNet18 Backbone (pretrained)
# -----
resnet = resnet18(weights=ResNet18_Weights.IMAGENET1K_V1)
# no fully connected layer, no average pooling. keep only convolutional layers
self.backbone = nn.Sequential(*list(resnet.children())[:-2])
# freeze weights of the backbone model, if requested
if freeze_backbone:
    for param in self.backbone.parameters():
        param.requires_grad = False

# number of channels of output for ResNet18 = 512
backbone_output_channels = 512

# -----
# 2. YOLO-style Detection Head
# -----
self.detection_head = nn.Sequential(
    # Conv layer 1: less channels
    nn.Conv2d(backbone_output_channels, 256, kernel_size=3, padding=1),
    nn.BatchNorm2d(256),
    nn.LeakyReLU(0.1),
    # Conv layer 2: more processing
    nn.Conv2d(256, 128, kernel_size=3, padding=1),
    nn.BatchNorm2d(128),
    nn.LeakyReLU(0.1),

    # Conv layer 3: final output
    # Output channels = 5 * num_boxes (x, y, w, h, conf για κάθε box)
    nn.Conv2d(128, 5 * num_boxes, kernel_size=1),
)

```

✓ 0.1s

Εικόνα 4. Αρχιτεκτονική μοντέλου: ResNet18 backbone και YOLO-style κεφαλή

Η συνάρτηση κόστους που χρησιμοποιείται βασίζεται στη λογική του YOLO και περιλαμβάνει συνιστώσες που αφορούν την ακρίβεια της τοποθέτησης των bounding boxes και την πρόβλεψη της ύπαρξης αντικειμένων. Διαφορετικά βάρη χρησιμοποιούνται για την ισορροπία μεταξύ περιοχών που περιέχουν αντικείμενα και περιοχών που δεν περιέχουν.

```

# total loss, with w
total_loss = (self.lambda_coord * coord_loss + conf_loss_obj + self.lambda_noobj * conf_loss_noobj)

# normalizing with batch size
total_loss = total_loss / batch_size

return total_loss

# build loss function...
criterion = YOLOLoss(grid_size=GRID_SIZE, num_boxes=NUM_BOXES_PER_CELL, lambda_coord=LAMBDA_COORD, lambda_noobj=LAMBDA_NOOBJ)

```

✓ 0.0s

Εικόνα 5. Συνάρτηση κόστους (YOLO Loss)

Η διαδικασία εκπαίδευσης περιλαμβάνει επαναληπτικά βήματα forward pass, υπολογισμό του loss, backpropagation και ενημέρωση των βαρών με χρήση του Adam optimizer.

Επιπλέον, χρησιμοποιείται scheduler για δυναμική προσαρμογή του ρυθμού μάθησης και αποθηκεύεται το καλύτερο μοντέλο με βάση την απόδοση στο validation set.

```
def train_one_epoch(model, train_loader, criterion, optimizer, device):  
    """  
    for 1 epoch, returns:  
    | average_loss: per epoch  
    """  
    model.train()  
    total_loss = 0.0  
  
    progress_bar = tqdm(train_loader, desc="Training")  
    for images, targets in progress_bar:  
        # transfer to device (cpu/gpu)  
        images = images.to(device)  
        targets = targets.to(device)  
  
        # Forward pass  
        predictions = model(images)  
        loss = criterion(predictions, targets)  
  
        # Backward pass  
        optimizer.zero_grad()  
        loss.backward()  
        optimizer.step()  
  
        # progress bar update  
        total_loss += loss.item()  
        progress_bar.set_postfix({'loss': loss.item()})  
  
    average_loss = total_loss / len(train_loader)  
    return average_loss
```

✓ 0.0s

Εικόνα 6. Συνάρτηση εκπαίδευσης μίας εποχής (train_one_epoch)

Κατά τη φάση της επαλήθευσης, το μοντέλο αξιολογείται σε δεδομένα που δεν έχουν χρησιμοποιηθεί για εκπαίδευση, με στόχο τη μέτρηση της γενίκευσης. Η διαδικασία αυτή βοηθά στην αποφυγή υπερπροσαρμογής και στη βελτιστοποίηση των υπερπαραμέτρων.

```
def validate(model, val_loader, criterion, device):
    """
    Returns:
        average_loss: for validation set
    """
    model.eval()
    total_loss = 0.0

    with torch.no_grad():
        for images, targets in val_loader:
            images = images.to(device)
            targets = targets.to(device)

            predictions = model(images)
            loss = criterion(predictions, targets)

            total_loss += loss.item()

    average_loss = total_loss / len(val_loader)
    return average_loss
```

✓ 0.0s

Εικόνα 7. Συνάρτηση επαλήθευσης (validate)


Τέλος, τα αποτελέσματα παρουσιάζονται σε γραφήματα, όπου οι προβλέψεις μετατρέπονται σε bounding boxes και απεικονίζονται πάνω στις αρχικές εικόνες, συνοδευόμενες από τιμές confidence.

5. Υπερπαράμετροι και Επιλογές

Η επιλογή των υπερπαραμέτρων έγινε με στόχο την ισορροπία μεταξύ ακρίβειας και αποδοτικότητας. Ο ρυθμός μάθησης επιλέχθηκε χαμηλός ώστε να διασφαλιστεί σταθερή εκπαίδευση, ενώ το μέγεθος batch επιτρέπει επαρκή εκμετάλλευση της διαθέσιμης μνήμης. Το μέγεθος grid είναι συμβατό με το output του ResNet, ενώ η χρήση δύο bounding boxes ανά κελί επιτρέπει την ανίχνευση πολλαπλών προσώπων στην ίδια περιοχή. Επιπλέον, τα βάρη της συνάρτησης κόστους ρυθμίστηκαν ώστε να δοθεί μεγαλύτερη έμφαση στην ακρίβεια εντοπισμού.

6. Εκπαίδευση και Αποτελέσματα

Η εκπαίδευση πραγματοποιήθηκε για 10 epochs, κατά τη διάρκεια των οποίων καταγράφηκε η εξέλιξη του training και validation loss. Παρατηρείται σταδιακή μείωση του loss, γεγονός που υποδηλώνει ότι το μοντέλο μαθαίνει επιτυχώς. Το validation loss χρησιμοποιείται ως βασικό κριτήριο επιλογής του καλύτερου μοντέλου.



Εικόνα 8. Καμπύλες Training και Validation Loss (ResNet)

Η οπτικοποίηση των αποτελεσμάτων δείχνει ότι το μοντέλο είναι ικανό να εντοπίζει πρόσωπα σε εικόνες, αν και σε ορισμένες περιπτώσεις παρατηρούνται ψευδώς θετικές ανιχνεύσεις ή δυσκολίες σε μικρά πρόσωπα.



Εικόνα 9. Παράδειγμα ανίχνευσης προσώπων με τιμές confidence

7. Συμπεράσματα

Το προτεινόμενο σύστημα αξιοποιεί επιτυχώς τη συνδυαστική δύναμη ενός προεκπαιδευμένου backbone και μιας YOLO-style κεφαλής για την ανίχνευση προσώπων. Η χρήση του ResNet επιτρέπει την αξιοποίηση ήδη μαθημένων χαρακτηριστικών, ενώ η YOLO προσέγγιση καθιστά το σύστημα αποδοτικό και γρήγορο.

Παρά τα θετικά αποτελέσματα, υπάρχουν περιορισμοί που σχετίζονται με την ακρίβεια σε δύσκολες περιπτώσεις και την ανάγκη για περαιτέρω βελτιστοποίηση των υπερπαραμέτρων.

Ερώτημα 3 - Εντοπισμός Προσώπων με Vision Transformer

1. Εισαγωγή & Στόχος

Ο στόχος του Ερωτήματος 3 ήταν η υλοποίηση ενός εναλλακτικού νευρωνικού δικτύου για τον εντοπισμό προσώπων στο WIDER FACE dataset. Αντί της χρήσης ενός ResNet ως κύριου κορμού εξαγωγής χαρακτηριστικών (όπως στο Ερώτημα 2), υλοποιήθηκε μια αρχιτεκτονική βασισμένη σε Vision Transformer (ViT), και συγκεκριμένα το DeiT-Small, διατηρώντας παράλληλα μια κεφαλή ανίχνευσης τύπου YOLO (YOLO-style head).

Ο λόγος επιλογής ενός ViT είναι η ικανότητά του να μοντελοποιεί το global context των εικόνων μέσω του μηχανισμού self-attention, κάτι που είναι ιδιαίτερα χρήσιμο για τον εντοπισμό πολλαπλών ή επικαλυπτόμενων προσώπων, σε αντίθεση με τα παραδοσιακά CNNs (όπως το ResNet) που βασίζονται σε τοπικά (local) φίλτρα.

2. Αρχιτεκτονική του Νευρωνικού Δικτύου

Η αρχιτεκτονική που αναπτύχθηκε (υλοποιημένη ως κλάση ViT_YOLO_Detector στο PyTorch Lightning) αποτελείται από δύο κύρια μέρη:

Το πρώτο μέρος αποτελείται από τον κύριο κορμό ο οποίος είναι ένας προεκπαιδευμένος μετασχηματιστής DeiT-Small, ο οποίος παίρνει ως είσοδο έναν τένσορα διαστάσεων $3 \times 224 \times 224$. Συγκεκριμένα το μοντέλο που χρησιμοποιήθηκε είναι προεκπαιδευμένο στο ImageNet dataset και είναι το μοντέλο `deit_small_patch16_224` της βιβλιοθήκης `timm`. Το δίκτυο εξάγει 196 patch tokens διάστασης 384 το καθένα. Τα αρχικά layers του backbone "παγώθηκαν" (frozen) και "ξεπαγώθηκαν" προς εκπαίδευση μόνο τα 6 τελευταία blocks προκειμένου να προσαρμοστούν στο task του Face Detection χωρίς να καταστραφούν τα γενικά χαρακτηριστικά που είχαν μάθει από το ImageNet.

Το δεύτερο μέρος αποτελείται από την κεφαλή τύπου YOLO. Τα 196 patch tokens του DeiT αναδιατάχθηκαν (reshaped) με κατάλληλο τρόπο ώστε να σχηματίσουν ένα 2D Feature Map διάστασης $384 \times 14 \times 14$, επιτρέποντας τη χρήση συνελκτικών επιπέδων (Conv layers). Η κεφαλή του YOLO αποτελείται από 3 επίπεδα.

Πίνακας 1. Επίπεδα Κεφαλής YOLO

Επίπεδο	Διαστάσεις Εισόδου	Λειτουργίες (Operations)	Διαστάσεις Εξόδου	Περιγραφή / Ρόλος
Είσοδος	(32, 384, 14, 14)	-	(32, 384, 14, 14)	Το 2D Feature Map που προκύπτει από την αναδιάταξη των patch tokens του DeiT-Small.
1ο Επίπεδο	(32, 384, 14, 14)	Conv2d (384 -> 256) BatchNorm2d LeakyReLU	(32, 256, 14, 14)	Αρχική εξαγωγή χαρακτηριστικών σχετικών με πρόσωπα και μείωση του βάθους (από 384 σε 256 κανάλια).
2ο Επίπεδο	(32, 256, 14, 14)	Conv2d (256 -> 128) BatchNorm2d LeakyReLU	(32, 128, 14, 14)	Περαιτέρω συμπίεση (από 256 σε 128 κανάλια), διατηρώντας την πιο σημαντική πληροφορία.

3ο Επίπεδο (Έξοδος)	(32, 128, 14, 14)	Conv2d (128 -> 10) Sigmoid	(32, 10, 14, 14)	Τελική πρόβλεψη. Δημιουργεί 10 κανάλια που αντιστοιχούν σε 2 bounding boxes × 5 παραμέτρους (C, x, y, w, h). Η Sigmoid περιορίζει τις τιμές στο [0, 1].
----------------------------	-------------------	-------------------------------	------------------	---

Η τελική έξοδος είναι ένας τένσορας μεγέθους **(32, 14, 14, 10)**. Αυτό σημαίνει ότι δημιουργείται ένα grid 14x14, όπου κάθε κελί προβλέπει 2 bounding boxes. Κάθε box έχει 5 παραμέτρους: [confidence, cx, cy, w, h] (πιθανότητα ύπαρξης αντικειμένου και συντεταγμένες/διαστάσεις).

Με αυτή την αρχιτεκτονική το μοντέλο διαθέτει συνολικά περίπου ~22.8 εκατομμύρια παραμέτρους, από τις οποίες τα ~11.8 εκατ. (51.8%) είναι εκπαιδευσιμα.

3. Διαδικασία Εκπαίδευσης & Σύνολο Δεδομένων (WIDER FACE)

Φορτώθηκε το training και validation set του WIDER FACE. Κατά το training εφαρμόστηκε Data Augmentation (όπως Color Jitter και Random Horizontal Flip) για αύξηση της ικανότητας γενίκευσης του μοντέλου. Πρόσωπα με διαστάσεις μικρότερες από 20px αγνοήθηκαν.

Χρησιμοποιήθηκε μια προσαρμοσμένη YOLO Loss με δύο μέρη. Το πρώτο μέρος αποτελείται από το MSE (Mean Squared Error) για τις συντεταγμένες των κέντρων (x,y) και MSE για την τετραγωνική ρίζα των πλάτους και ύψους (w, h), ώστε τα λάθη στα μικρά κουτιά να τιμωρούνται αναλογικά περισσότερο. Το δεύτερο είναι το MSE με διαφορετικά βάρη ανάλογα με το αν το κελί περιέχει πρόσωπο (obj) ή όχι (no-obj).


Τέλος, Επιλέχθηκε ο AdamW μαζί με learning rate scheduler CosineAnnealingLR, έως 50 εποχές.

4. Hyperparameter Search (Επιλογή Υπερπαραμέτρων)

Για να βρεθούν οι ιδανικές ρυθμίσεις για το μοντέλο, πραγματοποιήθηκε πειραματισμός (Grid Search) πάνω στο validation set. Συγκεκριμένα ελέγχθηκαν οι εξής τιμές, για το learning rate (LR) οι τιμές [1e-5, 3e-5, 1e-4] και για το βάρος localization loss (lambda_coord) οι τιμές [5.0, 7.0]. Κάθε συνδυασμός εκπαιδεύτηκε για 5 εποχές. Από την οπτικοποίηση και την αξιολόγηση των Validation Loss προέκυψε ότι τα καλύτερα αποτελέσματα επιτεύχθηκαν με τις εξής τιμές:

- **Βέλτιστο Learning Rate:** $1e-4$
- **Βέλτιστο lambda_coord:** 5.0


Validation Loss: 7.4899, το μικρότερο από όλα τα πειράματα.



Εικόνα 10. Hyperparameter Search


5. Πλήρης Εκπαίδευση

Αφού επιλέχθηκαν οι καλύτερες υπερπαράμετροι, πραγματοποιήθηκε η τελική πλήρης εκπαίδευση του μοντέλου ViTYOLODetector. Για την αποφυγή υπερεκπαίδευσης (overfitting) προστέθηκε η τεχνική EarlyStopping η οποία παρακολουθεί το val_loss με "υπομονή" (patience) 12 εποχών. Παράλληλα, το callback ModelCheckpoint αποθήκευε αυτόματα την έκδοση του μοντέλου με το μικρότερο Validation Loss στο directory vit_yolo_ckpts/. Μετά το πέρας της εκπαίδευσης τα βάρη του καλύτερου μοντέλου αποθηκεύτηκαν στο τελικό αρχείο final_vit_yolo.pth. Τέλος, εξήχθησαν τα γραφήματα (Learning curves) με την εξέλιξη του σφάλματος για το Training Loss και το Validation Loss ανά εποχή, ώστε να επιβεβαιωθεί η ομαλή σύγκλιση (convergence) του μοντέλου κατά τον εντοπισμό προσώπων. Κατά την εκπαίδευση το μοντέλο έφτασε τις 16 εποχές, καθώς στη συνέχεια ενεργοποιήθηκε το early stopping αφού παρότι το loss του training μειωνόταν, το validation loss αυξανόταν υποδεικνύοντας overfitting. Η γραφική του loss δίνεται και παρακάτω.



Εικόνα 11. Learning Curves


Στην συνέχεια έγινε ένας έλεγχος για την επιλογή του καλύτερου confidence threshold πάνω στο validation dataset με βάση τις μετρικές precision, F1 και Recall. Οι τιμές που δοκιμάστηκαν ήταν [0.6, 0.7, 0.8] και τα καλύτερα metric παράχθηκαν με το 0.6. Οι καμπύλες φαίνονται και παρακάτω:



Εικόνα 12. Confidence Threshold


6. Αποτελέσματα

Έχοντας εκπαιδεύσει το μοντέλο έγινε οπτικοποίηση συγκεκριμένων εικόνων και συγκρίνεται με το ground truth. Στο γράφημα φαίνεται ότι ο ViT καταφέρνει να αναγνωρίσει σωστά τις φωτογραφίες που υπάρχει ένα πρόσωπο ενώ ανταπεξέρχεται σε έναν βαθμό και σε φωτογραφίες με πολλά πρόσωπα όπου υπάρχουν όμως και πολλά false positives και false negatives αφού αγνοούνται πρόσωπα ιδιαίτερα αυτά με μικρότερες διαστάσεις.



Εικόνα 13. ViT πρόβλεψη σε σχέση με την πραγματικότητα


Τα attention maps οπτικοποιούν την εσωτερική λειτουργία του Vision Transformer (ViT), δείχνοντας ποια περιοχές της εικόνας θεωρεί σημαντικές το μοντέλο κατά την επεξεργασία. Στο παρακάτω διάγραμμα φαίνεται ότι ο μετασχηματιστής επιτυχώς διαχωρίζει την περιοχή που υπάρχουν τα πρόσωπα από την υπόλοιπη περιοχή.



Εικόνα 14. ViT Attention Map

Από το attention map μπορούμε να καταλάβουμε ότι ο transformer βρίσκει σωστά τις περιοχές που υπάρχουν πρόσωπα, αλλά παρατηρείται κάποιο scatter στις περιπτώσεις που υπάρχουν πολλά πρόσωπα μαζί, κάνοντας δύσκολο το ακριβές annotation.

Τέλος δίνεται το διάγραμμα εξέλιξης του attention ανά ViT block.



Εικόνα 15. Εξέλιξη Self-Attention

Η Εικόνα 15 δείχνει πως ο transformer ξεκινάει από την αρχική εικόνα και όπως αυξάνονται τα blocks κάνει focus πρώτα στον άνθρωπο και τέλος στο πρόσωπο, χωρίζοντάς το από την υπόλοιπη εικόνα.

Μέρος Β

Ερώτημα 6 - Αναγνώριση Συναισθημάτων με Συνελικτικό Νευρωνικό Δίκτυο (CNN)

1. Dataset

Το Dataset που χρησιμοποιήθηκε για την εκπαίδευση του CNN είναι το FER – 2013. Περιέχει grayscale εικόνες των 48x48 πίξελ. Η κάθε εικόνα αποτυπώνει ένα πρόσωπο με ένα εκ των 7 συναισθημάτων: happy, neutral, sad, fear, angry, surprise, disgust.

Η κατανομή του πλήθους των εικόνων για το κάθε συναίσθημα έχει ως εξής:

Πίνακας 2. Κατανομή εικόνων ανά συναίσθημα (FER-2013)

Συναίσθημα	Πλήθος εικόνων
Angry	3595
Disgust	392
Fear	3687
Happy	6493
Neutral	4469
Sad	4347
Surprise	2854

Βλέπουμε ότι υπάρχει μεγάλη ανισορροπία στο Dataset ειδικά όσον αφορά το πλήθος των εικόνων με συναίσθημα disgust (392). Αυτό αντιμετωπίζεται με την χρήση Βαρών (weights) κατά την διαδικασία της εκπαίδευσης. Δηλαδή εφαρμόζεται penalty αντιστρόφως ανάλογο του πλήθους των εικόνων για κάθε συναίσθημα.

2. Split

- Test (7,178): Το σύνολο των εικόνων Test δεν χρησιμοποιούνται κατά την διαδικασία της εκπαίδευσης, και ούτε κατά την διαδικασία επιλογής αρχιτεκτονικής και υπερπαραμέτρων. Το μοντέλο συνάντησε πρώτη φορά αυτές τις εικόνες κατά την τελική αξιολόγησή του.
- Train (28,709): Το Dataset δεν παρείχε split Training/Validation/Testing (μόνο Training/Testing), οπότε οι Training εικόνες που παρέχονται χωρίστηκαν σε Training (25,837) και Validation (2,872). Διατηρήθηκε η αναλογία των συναισθημάτων και σε αυτό το split.

Σημειώνεται ότι για τις Training εικόνες χρησιμοποιήθηκε και η τεχνική augmentation για την αύξηση των Training Samples και της αποφυγής overfitting στο μικρό πλήθος εικόνων (οριζόντια αναστροφή, μικροί affine μετασχηματισμοί, τυχαία διαγραφή pixels).

3. Architecture

Η αρχιτεκτονική του μοντέλου είναι τύπου VGG με τα εξής layers:

- Τέσσερα μπλοκ συνέλιξης στη σειρά όπου εφαρμόζονται:
 - Δύο layers συνέλιξης (3x3)
 - Batch normalization και ReLU
 - Maxpool και Dropout

Αυτό οδηγεί την «εικόνα» να συρρικνώνεται στις 2 διαστάσεις (48->24->12->6->3) και να επεκτείνεται στην τρίτη -features- (64->128->256->512)

- Ένα μικρό classifier head:
 - Global average pooling: Κάθε ένα από τα 512 feature maps γίνεται ένας αριθμός.
 - Dense layer: (512->256) με Batch Normalization, ReLU, 50% dropout.
 - Final layer: (256->7) με την τελική πρόβλεψη

4. Training

Τα χαρακτηριστικά της εκπαίδευσης είναι τα ακόλουθα:

- Adam optimizer (learning rate 0.001, weight decay 0.0001).
- Class weighted cross-entropy loss.
- Προγραμματιστής learning rate: Όταν η ακρίβεια στο validation set σταματάει να βελτιώνεται για 4 εποχές, ο ρυθμός εκπαίδευσης μειώνεται στο μισό (για να επιτραπεί το fine tuning)
- Early stopping: Αν η ακρίβεια στο validation set δεν βελτιωθεί για 12 εποχές, το μοντέλο πηγαίνει πίσω στην καλύτερη εποχή του.

Με την επιλογή `LOAD_PRETRAINED=True` το μοντέλο δεν ξαναεκπαιδεύεται και φορτώνεται η προηγούμενή του έκδοση.

5. Results

Τα αποτελέσματα αποθηκεύονται σε ξεχωριστό φάκελο για κάθε run.

Βέλτιστη ακρίβεια (Validation): **68.25%**

Βέλτιστη ακρίβεια (Test): **68.12%**

Αυτό σημαίνει ότι το μοντέλο γενικεύει ικανοποιητικά ακόμα και σε δεδομένα που δεν έχει δει ούτε έμμεσα (μέσω υπερπαραμέτρων). Δεδομένου ότι οι άνθρωποι εμφανίζουν 65-68% ακρίβεια σε αυτό το dataset, το αποτέλεσμα του μοντέλου είναι ικανοποιητικό.


Πιο αναλυτικά, εμφάνισε τα παρακάτω για κάθε συναίσθημα:

Πίνακας 3. Αναφορά ταξινόμησης CNN (ανά συναίσθημα)

Emotion	Precision	Recall	F1-score
angry	0.597	0.634	0.615
disgust	0.609	0.757	0.675
fear	0.544	0.461	0.499
happy	0.893	0.859	0.876
neutral	0.594	0.711	0.647
sad	0.602	0.502	0.547
surprise	0.750	0.842	0.794
Overall accuracy			0.681
Macro avg	0.656	0.681	0.665

Εμφάνισε μεγαλύτερη ακρίβεια σε εικόνες happy, τόσο λόγω του πλήθους τους, όσο και (πιθανότατα) λόγω των εντονότερων χαρακτηριστικών (χαμόγελο) που έχουν αυτές οι εικόνες.


Το αντίστοιχο confusion matrix:



Εικόνα 16. Confusion Matrix (CNN, κανονικοποιημένο)

Παρατηρούμε ότι τα συναισθήματα fear και sad έχουν την μεγαλύτερη διάχυση σε άλλα συναισθήματα. Μαζί με τα στατιστικά αποθηκεύονται και εικόνες οι οποίες κατηγοριοποιήθηκαν λανθασμένα από το μοντέλο για να εξετάσουμε πιθανές αιτίες.

Μερικά χαρακτηριστικά παραδείγματα:



Χαρακτηρίστηκε neutral ενώ είναι sad



Χαρακτηρίστηκε sad ενώ είναι fear




Χαρακτηρίστηκε angry ενώ είναι fear


Εικόνα 17. Παραδείγματα λανθασμένης ταξινόμησης (πρόβλεψη / πραγματική κλάση)

Βλέπουμε ότι ο χαρακτηρισμός εικόνων στο FER dataset δεν είναι απολύτως αντικειμενικός, κάτι που σημαίνει ότι η ακρίβεια του μοντέλου ενδέχεται να είναι καλύτερη από ότι υποδεικνύουν οι αριθμοί.

Τέλος έχουμε τις Training καμπύλες που περιγράφουν μια αναμενόμενη πορεία για ένα νευρωνικό δίκτυο με μέγεθος και πολυπλοκότητα κατάλληλα για το Dataset. Η ακρίβεια στο validation set είναι γενικά ψηλότερη από την ακρίβεια του Training (λόγω dropout), μέχρι το σημείο όπου ξεκινάει το overfitting και η ακρίβεια στο validation σταματάει να βελτιώνεται ουσιαστικά. Η βέλτιστη εποχή ήταν η 92.



Εικόνα 18. Καμπύλες Loss (Training & Validation) — CNN



Εικόνα 19. Καμπύλες Accuracy (Training & Validation) — CNN

Η διαδικασία εκπαίδευσης απαιτούσε ~10 δευτερόλεπτα ανά εποχή σε κάρτα γραφικών (RTX A4000).

Ερώτημα 7 - Αναγνώριση Συναισθημάτων με Vision Transformer

1. Data Handling, Regularization και Stratified Split

Το σύνολο δεδομένων FER-2013 χαρακτηρίζεται από class imbalance. Για παράδειγμα, η κλάση "Happy" κυριαρχεί, ενώ η κλάση "Disgust" υποεκπροσωπείται δραματικά. Για τον λόγο αυτό, εφαρμόστηκε Stratified 10% Split. Αυτή η προσέγγιση εγγυάται ότι η εκ των προτέρων (a priori) κατανομή των συναισθημάτων διατηρείται αυστηρά αναλογική τόσο στο Train Set όσο και στο Validation Set.

- Angry: 3595 images
- Disgust: 392 images
- Fear: 3687 images
- Happy: 6493 images
- Neutral: 4469 images
- Sad: 4347 images
- Surprise: 2854 images

Παρά το Stratified split, η ανισορροπία του συνόλου παρέμενε. Αντιμετωπίστηκε με τον δυναμικό υπολογισμό βαρών (Class Weights) τα οποία ενσωματώθηκαν στη συνάρτηση απώλειας (Cross-Entropy Loss), τιμωρώντας το μοντέλο πιο αυστηρά όταν κάνει λάθος στις σπάνιες κλάσεις.

Εφαρμόστηκαν γεωμετρικοί μετασχηματισμοί (Horizontal Flip, Rotation) και Random Erasing ($p=0.2$). Το Random Erasing αποδείχθηκε πολύ σημαντικό για το ViT, διαγράφοντας τυχαία ορθογώνια τμήματα της εικόνας κατά την εκπαίδευση το μοντέλο εξαναγκάζεται να μην εστιάζει αποκλειστικά σε ένα μεμονωμένο χαρακτηριστικό. Αντίθετα, μαθαίνει να

αξιοποιεί τον μηχανισμό Self-Attention για να εντοπίζει συνδυαστικά χαρακτηριστικά στον υπόλοιπο χώρο του προσώπου αυξάνοντας το robustness του συστήματος.

2. Αρχιτεκτονική Μοντέλου και Βελτιστοποίηση

Χρησιμοποιήθηκε η παραλλαγή ViT-Tiny (vit_tiny_patch16_224). Δεδομένου ότι οι αρχικές εικόνες του συνόλου FER-2013 έχουν διαστάσεις 48x48 pixels, εφαρμόστηκε αναπροσαρμογή μεγέθους (resize) σε 224x224 pixels κατά το στάδιο της προεπεξεργασίας, προκειμένου να ικανοποιηθούν οι αυστηρές χωρικές απαιτήσεις του δικτύου. Στη συνέχεια, η εικόνα εισόδου αποδομείται σε ένα πλέγμα από 196 μη-επικαλυπτόμενα "patches" διάστασης 16x16, τα οποία μετατρέπονται σε διανύσματα μέσω γραμμικής προβολής (linear embedding). Αυτή η αρχιτεκτονική επιτρέπει στο μοντέλο να βλέπει τα long-range dependencies της γεωμετρίας του προσώπου από το πρώτο κιόλας επίπεδο. Εφαρμόστηκε πλήρης επανεκπαίδευση και των 5.53 εκατομμυρίων παραμέτρων του μοντέλου.

Για την ταχεία και ομαλή σύγκλιση, η στρατηγική βελτιστοποίησης περιλάμβανε τα εξής:

- **Label Smoothing:** Στα προβλήματα αναγνώρισης συναισθήματος, τα όρια μεταξύ των κλάσεων είναι συχνά ασαφή. Προστέθηκε Label Smoothing (0.1) στη συνάρτηση κόστους, μετατρέποντας τα hard labels (0 ή 1) σε soft probabilities. Αυτό απέτρεψε το μοντέλο από το να γίνεται overconfident, βελτιώνοντας τη γενίκευση.
- **AdamW & Cosine Annealing:** Αξιοποιήθηκε ο AdamW Optimizer ($lr=1e-4$) σε συνδυασμό με Cosine Annealing Scheduler, ο οποίος μείωνε σταδιακά τον ρυθμό εκμάθησης ακολουθώντας ημιτονοειδή καμπύλη, αποφεύγοντας τον εγκλωβισμό σε τοπικά ελάχιστα.
- **Σταθερότητα & AMP:** Τα Transformers έχουν το πρόβλημα των exploding gradients στα αρχικά στάδια της εκπαίδευσης. Η εφαρμογή Gradient Clipping ($max_norm=1.0$) σταθεροποίησε την ανανέωση των βαρών. Επιπλέον, όλοι οι υπολογισμοί στη GPU εκτελέστηκαν μέσω Automatic Mixed Precision (AMP), προσφέροντας βέλτιστη διαχείριση μνήμης και ταχύτητας.

- Ο κύκλος εκπαίδευσης διήρκεσε 50 epochs, με ενεργοποιημένο μηχανισμό Early Stopping (patience=6).

3. Αξιολόγηση Αποτελεσμάτων

Το εκπαιδευμένο μοντέλο αξιολογήθηκε στο ανεξάρτητο Test Set, το οποίο αποτελείται από 7.178 άγνωστα προς το δίκτυο δείγματα. Δεδομένης της αρχικής ανισορροπίας των κλάσεων, η αξιολόγηση βασίστηκε στον υπολογισμό των μετρικών Precision, Recall και του F1-Score.


	Precision	Recall	F1-score	Support
Angry	0.5936	0.6221	0.6075	958
Disgust	0.6449	0.6216	0.6330	111
Fear	0.5696	0.5117	0.5391	1024
Happy	0.9223	0.8230	0.8698	1774
Neutral	0.6501	0.6164	0.6328	1233
Sad	0.5245	0.6191	0.5679	1247
Surprise	0.7692	0.8544	0.8096	831
Accuracy			0.6814	7178
Macro avg	0.6677	0.6669	0.6657	7178
Weighted avg	0.6902	0.6814	0.6838	7178

Πίνακας 4. Αξιολόγηση στο Test Set (ViT)


Αναλύοντας τις καμπύλες εκπαίδευσης παρατηρείται το φαινόμενο του overfitting που χαρακτηρίζει μοντέλα τύπου Transformer που εκπαιδεύονται σε περιορισμένα σύνολα δεδομένων. Συγκεκριμένα, ενώ το Train Loss μειώνεται συνεχώς, το Validation Loss παρουσιάζει ελάχιστο γύρω στην 7η-8η εποχή και εν συνεχεία αυξάνεται. Εδώ ακριβώς αποδεικνύεται η αναγκαιότητα της στρατηγικής Early Stopping που εφαρμόστηκε, η οποία

διέκοψε τη διαδικασία και διέσωσε τα βάρη στο σημείο της βέλτιστης γενίκευσης, πριν το μοντέλο αρχίσει να απομνημονεύει θόρυβο.

Ακόμα, από το Confusion Matrix φαίνεται εξαιρετική ακρίβεια στις κλάσεις "Happy" και "Surprise" οι οποίες διαθέτουν πολύ έντονα και διακριτά οπτικά χαρακτηριστικά. Αντιθέτως, στις κλάσεις "Neutral", "Sad" και "Fear" υπήρχε μία δυσκολία σωστής ταξινόμησης λόγω μικρο-εκφράσεων στα μάτια ή στα χείλη που τα καθιστά ασαφή ακόμα για το ανθρώπινο μάτι.



Εικόνα 20. Loss Curve & Validation Accuracy (ViT)




Εικόνα 21. Confusion Matrix (ViT)

4. Explainability και Attention Maps

Στους Vision Transformer έχουμε τη δυνατότητα οπτικοποίησης του Self-Attention από το τελικό Transformer Block. Κατά την οπτικοποίηση εντοπίστηκαν τα Attention Sinks όπου το δίκτυο αποθηκεύει το άχρηστο attention στα γωνιακά patches. Για την αντιμετώπισή του έγινε Suppression αντικαθιστώντας τις γωνιακές τιμές με τη διάμεσο του map πριν την κανονικοποίηση, το οποίο έκανε το heatmap να εστιάσει αποκλειστικά στα semantic χαρακτηριστικά του προσώπου.

Η μελέτη των Attention Maps αποκαλύπτει την ισχυρή ικανότητα του μοντέλου να εντοπίζει τα κατάλληλα Facial Action Units για τη λήψη αποφάσεων, λειτουργώντας με τρόπο εντυπωσιακά παρόμοιο με την ανθρώπινη αντίληψη.



Εικόνα 22. Attention Maps (ViT)

5. Σύγκριση Μεθόδων ViT και CNN

Παρά τις δύο τελείως διαφορετικές αρχιτεκτονικές που αξιοποιήθηκαν για την αναγνώριση συναισθημάτων, και τα δύο μοντέλα πέτυχαν σχεδόν ακριβώς την ίδια ακρίβεια (περίπου 68%). Σε συνδυασμό με το γεγονός ότι οι άνθρωποι έχουν και αυτοί 65-68% ποσοστό επιτυχίας στο συγκεκριμένο dataset, αυτό μας δείχνει ότι η ποιότητά του δεν είναι ιδανική για να επιτρέψει την εκπαίδευση μοντέλων με μεγαλύτερα ποσοστά επιτυχίας (πιθανώς λόγω λανθασμένων/πολύ υποκειμενικών ετικετών, μικρού πλήθους και ανάλυσης εικόνες, αντικείμενα μπροστά από πρόσωπα).

Πέραν, της ομοιότητας αυτής, οι δύο προσεγγίσεις είχαν αρκετές διαφορές:

- Χρόνος εκπαίδευσης και σύγκλιση: Το CNN αποδείχθηκε αρκετά πιο ελαφρύ (ανά εποχή) απαιτώντας 10 δευτερόλεπτα ανά εποχή σε κάρτα, χρειάστηκε όμως περισσότερες εποχές (~90) για να φτάσει σε σύγκλιση. Αντιθέτως η εκπαίδευση του ViT ήταν πιο χρονοβόρα (1 λεπτό ανά εποχή), ενώ συνέκλινε πιο γρήγορα (βέλτιστη ακρίβεια πριν τις 20 εποχές). Δηλαδή ο συνολικός χρόνος εκπαίδευσης είναι παρόμοιας τάξης μεγέθους για τα δύο μοντέλα, κάτι που εξηγείται και από το παρόμοιο μέγεθός τους (4.82M παράμετροι για το CNN και 5.5M για το ViT).
- Επεξηγησιμότητα: Τα CNNs είναι πιο απλά και κατανοητά όσον αφορά την λειτουργία (εξαγωγή απλών και στην συνέχεια σύνθετων features από την εικόνα), όμως δεν υπάρχουν ικανοποιητικές οπτικοποιήσεις που να αναλύουν τι οδήγησε στην συγκεκριμένη έξοδο για κάθε εικόνα. Αντιθέτως οι ViT, ενώ έχουν πιο σύνθετη αρχιτεκτονική, μπορούν να προσφέρουν attention maps τα οποία προδίδουν ποιες περιοχές της εικόνας οδήγησαν στην συγκεκριμένη έξοδο.

Bonus


Για το Bonus έγινε χρήση των εκπαιδευμένων μοντέλων, τον ViT-YOLO ανιχνευτή προσώπων και το EmotionCNN για αναγνώριση συναισθήματος. Η εφαρμογή λαμβάνει εικόνες από την κάμερα του υπολογιστή και επεξεργάζεται κάθε frame σε πραγματικό χρόνο μέσω της βιβλιοθήκης cv2. Συγκεκριμένα, κάθε frame μετατρέπεται σε RGB, κανονικοποιείται και περνά από τον ViT-YOLO ανιχνευτή ο οποίος επιστρέφει ένα grid 14×14 με 2 boxes ανά κελί. Τα bounding boxes που ξεπερνούν το confidence threshold (0.30) φιλτράρονται μέσω NMS με IoU threshold 0.20 για την αφαίρεση διπλών ανιχνεύσεων.

Στο δεύτερο μέρος του pipeline γίνεται η αναγνώριση των συναισθημάτων του κάθε αναγνωρισμένου προσώπου από το συνεκτικό μοντέλο EmotionCNN. Για κάθε πρόσωπο που εντοπίζεται, λαμβάνουμε το bounding box του και το επεκτείνουμε στην μικρότερη διάσταση ώστε οι διαστάσεις του να ταυτίζονται. Στην συνέχεια γίνεται resizing στις διαστάσεις 48x48 και η περιοχή ενδιαφέροντος μετατρέπεται σε grayscale σύμφωνα με τις εικόνες πάνω στις οποίες εκπαιδεύτηκε το δίκτυο. Η έξοδος του EmotionCNN είναι μία από τις 7 κλάσεις συναισθημάτων (Angry, Disgust, Fear, Happy, Sad, Surprise, Neutral).


Το αποτέλεσμα είναι η ζωντανή ανάδειξη των προσώπων με bounding boxes και η εμφάνιση του προβλεπόμενου συναισθήματος πάνω από το κάθε κουτί, μαζί με το confidence score της πρόβλεψης.

Καθώς το ViT YOLO εκπαιδεύτηκε στο wider dataset, η επίδοση εξαρτάται από το πόσα άτομα είναι στην εικόνα, το rose του προσώπου αλλά και από τον φωτισμό. Στις δοκιμές που έγιναν σε webcam 1080p υπήρχαν μεγάλες διαφορές ανάλογα με το πόσο καλός ήταν ο φωτισμός στο πρόσωπο ως προς την ανίχνευση στον χώρο, όσο και ο γενικός φωτισμός του χώρου που επηρεάζει και την ποιότητα της εικόνας προς ανίχνευση.

Στο κομμάτι του emotion recognition η διαφορά happy/sad ήταν εμφανής αλλά υπήρχαν κάποια misclassification ιδιαίτερα στο scared/surprised, angry/disgusted. Γενικότερα, ανάλογα και με την μορφολογία του κάθε προσώπου, συναισθήματα όπως angry και fear κυριαρχούν στις προβλέψεις περισσότερο από όσο θα περιμέναμε με βάση την απόδοση του μοντέλου στο FER dataset.



Εικόνα 23. Bonus — Ζωντανή ανίχνευση και αναγνώριση συναισθήματος (Angry)



Εικόνα 24. Bonus — Ζωντανή ανίχνευση και αναγνώριση συναισθήματος (Happy)